基因组结构层级体系

GENOME · HIERARCHICAL STRUCTURE · GENERATIVE GRAMMAR MODEL

§ 生成文法规则（GENERATIVE GRAMMAR RULES）

Genome → Chromosome⁺
// 由多条染色体组成

Chromosome → Chromatid × 2
// 姐妹染色单体对

Chromatid → Locus⁺
// 基因座的有序排列

Locus → Gene | NonCoding
// 编码区 或 非编码区

Gene → RegulatoryRegion CodingRegion
// 调控区 + 编码区

RegulatoryRegion → Promoter Enhancer*
// 启动子 + 零或多个增强子

CodingRegion → Exon (Intron Exon)*
// 外显子与内含子交替

Exon → Codon⁺
// 由密码子序列构成

Codon → Base Base Base
// 三个碱基编码一个氨基酸

Base → A | T | G | C
// 终结符：四种碱基

非终结符（Non-terminal） · 终结符（Terminal） · ⁺ = 一或多次 * = 零或多次 | = 或

LEVEL 1

碱基（Base） NUCLEOTIDE BASE

~0.34 nm / 碱基

终结符
A 腺嘌呤 T 胸腺嘧啶
G 鸟嘌呤 C 胞嘧啶

配对规则（WATSON-CRICK）
A ═══ T（2个氢键）
G ═══ C（3个氢键）

可视化
ATGCGATCAGTCAG

3个碱基 → 1个密码子

密码子（Codon） CODON

3 bp

LEVEL 2

编码规则
4^3 = 64 种密码子
编码 20 种氨基酸

示例
ATG → 甲硫氨酸（起始）
TAA → 终止信号

冗余性
多个密码子→同一氨基酸
（简并性）

密码子序列 → 外显子 / 内含子

LEVEL 3

外显子 / 内含子 EXON / INTRON

100 bp ~ 100 kbp

外显子（EXON）
编码蛋白质的序列
占基因组约 1.5%
类比：有意义的单词

内含子（INTRON）
转录后被剪切去除
占基因长度约 90%
类比：括号内的注释

5'—[外显子1]— [内含子1]—[外显子2]— [内含子2]—[外显子3]— 3' ← 前体mRNA

调控区 + 编码区 → 基因

LEVEL 4

基因（Gene） GENE

1 kbp ~ 2 Mbp

组成
启动子 + 外显子 + 内含子
+ 调控元件（增强子等）

数量（人类）
约 20,000 个蛋白质编码
基因
仅占基因组 1.5%

关键概念
等位基因（Allele）：
同一基因的不同版本

[启动子]—— [增强子]—— [外显子1]—— [内含子1]—— [外显子2]—— ···—— [终止子]

许多基因 + 非编码区 → 染色体

LEVEL 5

染色体（Chromosome） CHROMOSOME

50 Mbp ~ 250 Mbp

物理结构
DNA + 组蛋白 → 核小体
→ 染色质 → 染色体

数量（人类）
46 条（23对）
常染色体22对 + 性染色体
1对

基因座（LOCUS）
染色体上某基因的
固定物理位置

Chr1（最大） Chr2 ··· Chr21（最小） X / Y（性染色体）

全部染色体 → 基因组

LEVEL 6

基因组（Genome） GENOME

~3.2 Gbp（人类单倍体）

定义
一个生物体所含
全部遗传信息的总和

组成比例（人类）

信息量
约 750 MB
（4进制→2bit换算）

蛋白质编码区 1.5%
调控非编码区 ~8%
重复序列等 ~90%

§ 核心概念对比：基因 VS 染色体 VS 基因组

概念	定义	规模	类比（工学）	关系
基因 Gene	编码一种蛋白质（或RNA）的DNA片段，含调控区和编码区	1kbp～2Mbp 人类约20,000个	一个函数/子程序	是染色体的片段 是基因组的组成部分
染色体 Chromosome	DNA与蛋白质（组蛋白）结合形成的线状结构，携带多个基因	50～250Mbp 人类46条	一个代码模块/文件	包含许多基因 是基因组的分卷
基因组 Genome	一个生物体所有遗传信息的完整集合，含全部染色体	~3.2Gbp（人类）23对染色体	整个代码库/操作系统	包含全部染色体 包含全部基因
基因座 Locus	某基因在染色体上的固定物理位置	精确位置	内存地址	位置描述符 非独立实体
等位基因 Allele	同一基因座上，序列不同的基因版本（来自父方/母方）	基因大小	同一函数的不同版本	基因的变体 SNP是最小等位差异